

Rapport (2025.10.27) : Reconnaissance Automatique des Numéros de Plaque d'Immatriculation

Équipe de Recherche en Intelligence Artificielle

Abstract—Ce document présente l'évolution d'un système de reconnaissance automatique de plaques d'immatriculation utilisant le deep learning. Notre recherche compare une approche monolithique basée sur YOLOv11 avec une architecture hybride séparant la détection et la classification des caractères. Les résultats démontrent que l'approche hybride améliore significativement les performances tout en réduisant les coûts d'annotation de 25%. Le score F1 atteint 97.25% avec des perspectives d'optimisation vers l'excellence.

I. LE PASSÉ : APPROCHE MONOLITHIQUE

A. Architecture et Caractéristiques

Notre implémentation initiale utilisait un modèle YOLOv11 (You Only Look Once version 11) monolithique, caractérisé par :

- **Architecture unifiée** : Détection et classification simultanées en une seule passe
- **SimPLICITÉ d'implémentation** : Pipeline unique pour l'ensemble du processus
- **Traitement en temps réel** : Optimisé pour des applications nécessitant une faible latence

L'approche monolithique présentait cependant des limitations fondamentales :

$$\text{Temps d'annotation} = n \times t_{\text{caractère}} \times c_{\text{complexité}} \quad (1)$$

où n représente le nombre d'images, $t_{\text{caractère}}$ le temps par caractère, et $c_{\text{complexité}}$ la complexité de l'annotation simultanée en plusieurs classes.

B. Performances et Limitations

Les résultats obtenus avec l'architecture monolithique révélaient des contraintes significatives :

TABLE I

PERFORMANCES DU MODÈLE MONOLITHIQUE YOLOV11

Métrique	Valeur
mAP50	96.87%
mAP50-95	69.20%
Précision	94.97%
Rappel	92.23%
Score F1	93.58%
Temps d'inférence	19.6ms
Précision des prédictions confiantes (> 92 %)	83.54%

L'analyse critique de ces résultats montre que bien que le mAP50 soit acceptable, le mAP50-95 modeste indique

*Ce travail a été réalisé par le membre de l'équipe de laboratoire de recherche en IA de UATM GASA FORMATION.

une sensibilité aux variations de positionnement et de taille des caractères. Mais, le problème avec ce modèle est qu'il faut assez d'images de plaque labelisées dans la dataset améliorer la précision d'identification de numéro. Ce qui revient très coûteux en ressource humaine. De plus, pour labeliser une seule image de plaque, il faut plusieurs minutes à une personne. Enfin le mode de fonctionnement du modèle YOLO ne permettra pas d'atteindre des précisions extrême car pendant l'entraînement, le modèle optimise sur la classification de l'objet détecté alors que au début de l'entraînement, les boîtes de détection qu'il propose ne couvrent pas encore le numéro en question. Ce qui entraîne de mauvaises classifications.

II. LE PRÉSENT : ARCHITECTURE HYBRIDE

A. Conception du Nouveau Système

Face aux limitations du modèle monolithique, nous avons développé une architecture hybride décomposant le processus en deux modules spécialisés :

- **Module de détection** : YOLO optimisé pour la localisation précise des caractères
- **Module de classification** : Réseau neuronal dédié à l'identification des caractères rognés
- **Pipeline séquentiel** : Traitement en deux étapes distinctes mais intégrées

L'architecture hybride offre des avantages significatifs :

$$\text{Gain d'annotation} = \frac{t_{\text{monolithique}} - t_{\text{hybride}}}{t_{\text{monolithique}}} = 25\% \quad (2)$$

Avec $t_{\text{monolithique}}$ le temps d'annotation d'une plaque pour le modèle monolithique.

B. Performances et Analyse

Les résultats de l'architecture hybride démontrent une amélioration substantielle :

TABLE II

PERFORMANCES DU MODÈLE HYBRIDE

Métrique	Valeur
mAP50	99.47%
mAP50-95	74.01%
Précision	97.25%
Rappel	95.85%
Score F1	97.06%
Temps d'inférence	402ms
Précision des prédictions confiantes (> 92 %)	99.21%

L'analyse par classe révèle des performances exceptionnelles pour certains caractères :

$$F1\text{-score}_{\text{meilleur}} = 0.99 \quad (\text{caractères 2, 4, 9, C, E, K, M}) \quad (3)$$

tandis que certaines classes nécessitent une attention particulière :

$$F1\text{-score}_{\text{faible}} < 0.90 \quad (\text{lettres O, J, P, D}) \quad (4)$$

C. Avantages Constatés

L'architecture hybride présente plusieurs avantages décisifs :

- **Spécialisation** : Chaque module optimisé pour sa tâche spécifique
- **Réduction des coûts** : Annotation 4 fois plus rapide
- **Flexibilité** : Amélioration indépendante des modules
- **Robustesse** : Meilleure gestion des variations et du bruit

Le principal défi reste l'augmentation du temps de calcul global, compensé par les gains en précision et facilité de maintenance.

III. LE FUTURE : PERSPECTIVES D'AMÉLIORATION

Notre feuille de route stratégique vise l'excellence avec des objectifs quantifiés précis :

A. Objectifs Principaux

$$F1\text{-score}_{\text{cible}} = 99\% \quad \text{et} \quad \mathcal{L}_{\text{CrossEntropy}} = 1 \times 10^{-3} \quad (5)$$

où $\mathcal{L}_{\text{CrossEntropy}}$ représente la fonction de perte d'entropie croisée.

B. Stratégie d'Optimisation

Pour atteindre ces objectifs ambitieux, nous mettons en œuvre une stratégie multi-facettes :

- **Augmentation des données** : Collecte massive d'échantillons supplémentaires.
- **Data augmentation avancée** : Techniques de génération synthétique.
- **Optimisation d'architecture** : Fine-tuning des modèles actuels.
- **Focus sur les classes faibles** : Augmenter les échantillons des classes faibles.
- **Apprentissage par transfert** : Utilisation de modèles pré-entraînés.
- **Optimisation du temps de calcul** : Essayer de diminuer de le temps de calcul au niveau de chaque module afin de pouvoir atteindre au moins 50 frames par seconde.

C. Impact Attendu

L'atteinte de ces objectifs positionnera notre système parmi les solutions les plus performantes du marché, avec une fiabilité adaptée aux applications critiques nécessitant une précision extrême.

IV. GLOSSAIRE DES MÉTRIQUES

A. Exactitude (Accuracy)

$$\text{Exactitude} = \frac{\text{Nombre de prédictions correctes}}{\text{Nombre total de prédictions}} \quad (6)$$

Exemple : 96 prédictions correctes sur 100 → Exactitude = 96%

B. Précision (Precision)

Parmi les prédictions positives, proportion de véritables positifs.

$$\text{Précision} = \frac{\text{Vrais Positifs}}{\text{Vrais Positifs} + \text{Faux Positifs}} \quad (7)$$

Exemple : 85 véritables "A" parmi 90 prédictions "A" → Précision = 94.4%

C. Rappel (Recall)

Parmi les véritables positifs, proportion correctement identifiée.

$$\text{Rappel} = \frac{\text{Vrais Positifs}}{\text{Vrais Positifs} + \text{Faux Négatifs}} \quad (8)$$

Exemple : 92 "A" correctement identifiés sur 100 véritables "A" → Rappel = 92%

D. Score F1

Moyenne harmonique entre précision et rappel.

$$F1 = 2 \times \frac{\text{Précision} \times \text{Rappel}}{\text{Précision} + \text{Rappel}} \quad (9)$$

Exemple : Précision = 90%, Rappel = 95% → F1 = 92.4%

E. mAP (Mean Average Precision)

Moyenne des précisions sur différentes classes et seuils de confiance. Le mAP50 considère un chevauchement de 50% entre les boîtes détectées et les vérités terrain.

F. CrossEntropyLoss

Mesure l'erreur entre les distributions de probabilités prédites et réelles :

$$\mathcal{L}_{\text{CE}} = - \sum_{i=1}^N y_i \log(\hat{y}_i) \quad (10)$$

où y_i est la vérité terrain et \hat{y}_i la prédiction.

V. CONCLUSIONS

Notre recherche démontre la supériorité de l'architecture hybride pour la reconnaissance de plaques d'immatriculation. La séparation des tâches de détection et classification permet non seulement d'améliorer les performances métriques, mais aussi de réduire significativement les coûts de développement grâce à l'annotation simplifiée.

L'approche hybride atteint un score F1 de 97.25% avec une réduction de 25% du temps d'annotation, tout en maintenant une infrastructure adaptable et évolutive. Les perspectives d'optimisation vers un F1-score de 99% et une CrossEntropyLoss de 1×10^{-3} positionnent cette solution comme compétitive pour des applications industrielles exigeantes.