

Rapport (2025.10.27) Reconnaissance Automatique de Plaques d'Immatriculation

Équipe de Recherche en Intelligence Artificielle

Abstract—Ce document présente l'évolution d'un système de reconnaissance automatique de plaques d'immatriculation utilisant le deep learning. Notre recherche compare une approche monolithique basée sur YOLOv11 avec une architecture hybride séparant la détection et la classification des caractères. Les résultats démontrent que l'approche hybride améliore significativement les performances tout en réduisant les coûts d'annotation de 75%. L'exactitude atteint 95.85% avec des perspectives d'optimisation vers l'excellence.

I. LE PASSÉ : APPROCHE MONOLITHIQUE

A. Architecture et Caractéristiques

Notre implémentation initiale utilisait un modèle YOLOv11 (You Only Look Once version 11) monolithique, caractérisé par :

- **Architecture unifiée** : Détection et classification simultanées en une seule passe
- **Simplicité d'implémentation** : Pipeline unique pour l'ensemble du processus
- **Traitement en temps réel** : Optimisé pour des applications nécessitant une faible latence

L'approche monolithique présentait cependant des limitations fondamentales :

$$\text{Temps d'annotation} = n \times t_{\text{caractère}} \times c_{\text{complexité}} \quad (1)$$

où n représente le nombre d'images, $t_{\text{caractère}}$ le temps par caractère, et $c_{\text{complexité}}$ la complexité de l'annotation simultanée.

B. Performances et Limitations

Les résultats obtenus avec l'architecture monolithique révélaient des contraintes significatives :

TABLE I
PERFORMANCES DU MODÈLE MONOLITHIQUE YOLOV11

Métrique	Valeur
mAP50	96.87%
mAP50-95	69.20%
Précision	94.97%
Rappel	92.23%
Score F1	93.58%
Temps d'inférence	19.6ms

L'analyse critique de ces résultats montre que bien que le mAP50 soit acceptable, le mAP50-95 modeste indique une sensibilité aux variations de positionnement et de taille

des caractères. La nature conflictuelle de l'optimisation simultanée de la détection et de la classification limitait les performances maximales atteignables.

II. LE PRÉSENT : ARCHITECTURE HYBRIDE

A. Conception du Nouveau Système

Face aux limitations du modèle monolithique, nous avons développé une architecture hybride décomposant le processus en deux modules spécialisés :

- **Module de détection** : YOLO optimisé pour la localisation précise des caractères
- **Module de classification** : Réseau neuronal dédié à l'identification des caractères rognés
- **Pipeline séquentiel** : Traitement en deux étapes distinctes mais intégrées

L'architecture hybride offre des avantages significatifs :

$$\text{Gain d'annotation} = \frac{t_{\text{monolithique}} - t_{\text{hybride}}}{t_{\text{monolithique}}} = 75\% \quad (2)$$

B. Performances et Analyse

Les résultats de l'architecture hybride démontrent une amélioration substantielle :

TABLE II
PERFORMANCES DU MODÈLE HYBRIDE

Métrique	Valeur
mAP50	99.47%
mAP50-95	74.01%
Précision	96.53%
Rappel	95.85%
Temps d'inférence	0.0402s
Prédictions confiantes	92.54%
Précision des prédictions confiantes (> 92 %)	99.09%

L'analyse par classe révèle des performances exceptionnelles pour certains caractères :

$$\text{F1-score}_{\text{meilleur}} = 0.99 \quad (\text{caractères 2, 4, 9, C, E, K, M}) \quad (3)$$

tandis que certaines classes nécessitent une attention particulière :

$$\text{F1-score}_{\text{faible}} < 0.90 \quad (\text{lettres O, J, P, D}) \quad (4)$$

C. Avantages Constatés

L'architecture hybride présente plusieurs avantages décisifs :

- **Spécialisation** : Chaque module optimisé pour sa tâche spécifique
- **Réduction des coûts** : Annotation 4 fois plus rapide
- **Flexibilité** : Amélioration indépendante des modules
- **Robustesse** : Meilleure gestion des variations et du bruit

Le principal défi reste l'augmentation du temps de calcul global, compensé par les gains en précision et facilité de maintenance.

III. LE FUTURE : PERSPECTIVES D'AMÉLIORATION

Notre feuille de route stratégique vise l'excellence avec des objectifs quantifiés précis :

A. Objectifs Principaux

$$F1\text{-score}_{\text{cible}} = 99\% \quad \text{et} \quad \mathcal{L}_{\text{CrossEntropy}} = 1 \times 10^{-3} \quad (5)$$

où $\mathcal{L}_{\text{CrossEntropy}}$ représente la fonction de perte d'entropie croisée.

B. Stratégie d'Optimisation

Pour atteindre ces objectifs ambitieux, nous mettons en œuvre une stratégie multi-facettes :

- **Augmentation des données** : Collecte massive d'échantillons supplémentaires
- **Data augmentation avancée** : Techniques de génération synthétique
- **Optimisation d'architecture** : Fine-tuning des modèles actuels
- **Focus sur les classes faibles** : Augmenter les échantillons des classes faibles
- **Apprentissage par transfert** : Utilisation de modèles pré-entraînés

C. Impact Attendu

L'atteinte de ces objectifs positionnera notre système parmi les solutions les plus performantes du marché, avec une fiabilité adaptée aux applications critiques nécessitant une précision extrême.

IV. GLOSSAIRE DES MÉTRIQUES

A. Exactitude (Accuracy)

$$\text{Exactitude} = \frac{\text{Nombre de prédictions correctes}}{\text{Nombre total de prédictions}} \quad (6)$$

Exemple : 96 prédictions correctes sur 100 → Exactitude = 96%

B. Précision (Precision)

$$\text{Précision} = \frac{\text{Vrais Positifs}}{\text{Vrais Positifs} + \text{Faux Positifs}} \quad (7)$$

Exemple : 85 véritables "A" parmi 90 prédictions "A" → Précision = 94.4%

C. Rappel (Recall)

$$\text{Rappel} = \frac{\text{Vrais Positifs}}{\text{Vrais Positifs} + \text{Faux Négatifs}} \quad (8)$$

Exemple : 92 "A" correctement identifiés sur 100 véritables "A" → Rappel = 92%

D. Score F1

$$F1 = 2 \times \frac{\text{Précision} \times \text{Rappel}}{\text{Précision} + \text{Rappel}} \quad (9)$$

Exemple : Précision = 90%, Rappel = 95% → F1 = 92.4%

E. mAP (Mean Average Precision)

Moyenne des précisions sur différentes classes et seuils de confiance. Le mAP50 considère un chevauchement de 50% entre les boîtes détectées et les vérités terrain.

F. CrossEntropyLoss

Mesure l'erreur entre les distributions de probabilités prédites et réelles :

$$\mathcal{L}_{\text{CE}} = - \sum_{i=1}^N y_i \log(\hat{y}_i) \quad (10)$$

où y_i est la vérité terrain et \hat{y}_i la prédiction.

V. CONCLUSIONS

Notre recherche démontre la supériorité de l'architecture hybride pour la reconnaissance de plaques d'immatriculation. La séparation des tâches de détection et classification permet non seulement d'améliorer les performances métriques, mais aussi de réduire significativement les coûts de développement grâce à l'annotation simplifiée.

L'approche hybride atteint une exactitude de 95.85% avec une réduction de 75% du temps d'annotation, tout en maintenant une infrastructure adaptable et évolutive. Les perspectives d'optimisation vers un F1-score de 99% et une CrossEntropyLoss de 1×10^{-3} positionnent cette solution comme compétitive pour des applications industrielles exigeantes.