

Reconnaissance Automatique des Plaques d'Immatriculation

Du Monolithique à l'Hybride : Une Évolution Stratégique

Équipe de Recherche en Intelligence Artificielle

UATM GASA FORMATION

info@uatm-gasa.com

28 Octobre 2025

Plan de la Présentation

- 1 Introduction
- 2 Le Passé : Approche Monolithique
- 3 Le Présent : Architecture Hybride
- 4 Le Future : Perspectives d'Amélioration
- 5 Glossaire des Métriques
- 6 Conclusions

Problématique

La reconnaissance automatique de plaques d'immatriculation (ALPR) pose des défis majeurs :

- Variabilité des conditions d'éclairage
- Diversité des angles de vue
- Résolutions d'image variables
- Formats de plaques différents

Notre Objectif

Développer un système performant optimisant le compromis entre précision, coût et déploiement.

Caractéristiques principales :

- Architecture unifiée
- Détection + classification simultanées
- Pipeline simple
- Traitement temps réel

Formule de complexité :

$$T_{annotation} = n \times t_{car} \times C_{complex}$$

Limitation majeure : Annotation très coûteuse en temps et ressources humaines

Performances du Modèle Monolithique

Métrique	Valeur
mAP50	96.87%
mAP50-95	69.20%
Précision	94.97%
Rappel	92.23%
Score F1	93.58%
Temps d'inférence	19.6 ms
Précision (conf. > 92%)	83.54%

Problèmes identifiés

- mAP50-95 modeste (69.20%)
- Optimisation conflictuelle détection/classification
- Annotation très coûteuse (plusieurs minutes par image)

Conception en Deux Modules

- 1 **Module de détection** : YOLO optimisé pour localiser les caractères
- 2 **Module de classification** : Réseau neuronal dédié à l'identification

Gain d'annotation

$$\text{Gain} = \frac{t_{\text{monolithique}} - t_{\text{hybride}}}{t_{\text{monolithique}}} = 25\%$$

Annotation 4 fois plus rapide !

Métrique	Valeur
mAP50	99.47%
mAP50-95	74.01%
Précision	97.25%
Rappel	95.85%
F1	97.06%
Inférence	402 ms
Conf. > 92%	99.21%

Amélioration notable :

- **+3.48%** sur le F1-score
- **+2.60%** sur mAP50
- **+15.67%** sur précision haute confiance

Classes excellentes :

F1 = 0.99 pour 2, 4, 9, C, E, K, M

Comparaison des Deux Approches

Critère	Monolithique	Hybride
Score F1	93.58%	97.06%
mAP50	96.87%	99.47%
Précision (conf. > 92%)	83.54%	99.21%
Temps d'inférence	19.6 ms	402 ms
Coût d'annotation	Élevé	-25%
Flexibilité	Limitée	Élevée

Compromis

Gain substantiel en précision contre augmentation du temps de calcul

Avantages de l'Architecture Hybride

Avantages techniques :

- Spécialisation des modules
- Optimisation indépendante
- Meilleure robustesse au bruit
- Gestion améliorée des variations

Avantages opérationnels :

- Réduction de 25% du temps d'annotation, donc plus rapide
- Infrastructure évolutive
- Maintenance facilitée

Bilan

L'approche hybride offre un meilleur équilibre performance/coût avec une architecture adaptable.

Cibles Quantifiées

$$\text{F1-score}_{\text{cible}} = 99\%$$

$$\mathcal{L}_{\text{CrossEntropy}} = 1 \times 10^{-3}$$

Stratégies données :

- Collecte massive d'échantillons
- Data augmentation avancée
- Focus sur classes faibles

Stratégies modèles :

- Fine-tuning architecture
- Apprentissage par transfert
- Optimisation du temps de calcul

① Court terme (1-3 mois)

- Augmentation du dataset
- Amélioration des classes faibles (O, J, P, D)

② Moyen terme (3-6 mois)

- Optimisation architecturale
- Réduction temps de calcul (objectif : 50 FPS)

③ Long terme (6-12 mois)

- Atteinte F1-score = 99%
- Déploiement industriel

Précision

$$\text{Précision} = \frac{\text{Vrais Positifs}}{\text{Vrais Positifs} + \text{Faux Positifs}}$$

Parmi les prédictions positives, quelle proportion est correcte ?

Rappel

$$\text{Rappel} = \frac{\text{Vrais Positifs}}{\text{Vrais Positifs} + \text{Faux Négatifs}}$$

Parmi les vrais positifs, quelle proportion est identifiée ?

Score F1 et Cross-Entropy

Score F1

Moyenne harmonique entre précision et rappel :

$$F1 = 2 \times \frac{\text{Précision} \times \text{Rappel}}{\text{Précision} + \text{Rappel}}$$

Exemple : Précision = 90%, Rappel = 95% \blacklozenge F1 = 92.4%

Cross-Entropy Loss

Mesure l'erreur entre distributions prédites et réelles :

$$\mathcal{L}_{CE} = - \sum_{i=1}^N y_i \log(\hat{y}_i)$$

Plus cette valeur est faible, meilleure est la confiance du modèle.

Conclusions et Perspectives

Résultats Obtenus

- Architecture hybride **supérieure** à l'approche monolithique
- F1-score de **97.06%** (+3.48%)
- Réduction de **25%** du temps d'annotation
- Infrastructure évolutive et maintenable

Vision Future

Objectif F1 = 99% positionne cette solution comme **compétitive pour des applications industrielles exigeantes.**

Prochaines Étapes

Focus sur l'optimisation des classes faibles et la réduction du temps de calcul.

Équipe de Recherche

- Architectures Deep Learning
- Traitement d'images
- Évaluation performances

Institution

- UATM GASA FORMATION
- Laboratoire de Recherche en IA

Merci pour votre attention !

Questions ?

Commentaires et discussions

info@uatm-gasa.com