

# Rapport 2025-10-28 : Système de Reconnaissance Automatique des Plaques d'Immatriculation

## Du Monolithique à l'Hybride : Une Évolution Stratégique

Équipe de Recherche en Intelligence Artificielle

UATM GASA FORMATION

*info@uatm-gasa.com*

28 Octobre 2025

# Plan de la Présentation

- 1 Introduction
- 2 Le Passé : Approche Monolithique
- 3 Le Présent : Architecture Hybride
- 4 Le Future : Perspectives d'Amélioration
- 5 Glossaire des Métriques
- 6 Conclusions

## Problématique

La lecture des numéro de plaque d'immatriculation pose des défis majeurs :

- Variabilité des conditions d'éclairage
- Diversité des angles de vue et des polices d'écriture
- Résolutions d'image variables liée à celle de la caméra de prise de vue
- Formats de plaques différents

## Notre Objectif

Développer un système performant optimisant le compromis entre précision, coût et déploiement.

## Formule de complexité :

$$T_{annotation} = n \times t_{caracteres} \times C_{complex}$$

## Caractéristiques principales :

- Architecture unifiée
- Détection + classification simultanées
- Pipeline simple
- Traitement temps réel

**Limitation majeure :** Annotation très coûteuse en temps et ressources humaines afin d'atteindre de bonne précision dans la classification des caractères.

# Performances du Modèle Monolithique

Métrique	Valeur
mAP50	96.87%
mAP50-95	69.20%
Précision	94.97%
Rappel	92.23%
<b>Score F1</b>	<b>93.58%</b>
Temps d'inférence	333 ms
Précision (conf. > 92%)	83.54%

## Problèmes identifiés

- mAP50-95 modeste (69.20%)
- Optimisation conflictuelle détection/classification
- Annotation très coûteuse (plusieurs minutes par image)

## Conception en Deux Modules

- 1 **Module de détection** : YOLO optimisé pour localiser les caractères
- 2 **Module de classification** : Réseau neuronal dédié à l'identification

## Gain d'annotation

$$\text{Gain} = \frac{t_{\text{monolithique}} - t_{\text{hybride}}}{t_{\text{monolithique}}} = 25\%$$

**Annotation plus rapide !**

Métrique	Valeur
mAP50	99.47%
mAP50-95	74.01%
Précision	97.25%
Rappel	95.85%
<b>Score F1</b>	<b>97.06%</b>
Inférence	587 ms
Conf. > 92%	99.21%

## Amélioration notable :

- **+3.48%** sur le F1-score
- **+2.60%** sur mAP50
- **+15.67%** sur précision haute confiance

## Classes excellentes :

F1 = 0.99 pour 2, 4, 9, C, E, K, M

# Comparaison des Deux Approches

Critère	Monolithique	Hybride
Score F1	93.58%	<b>97.06%</b>
mAP50	96.87%	<b>99.47%</b>
Précision (conf. > 92%)	83.54%	<b>99.21%</b>
Temps d'inférence	<b>333 ms</b>	587 ms
Coût d'annotation	Élevé	<b>-25%</b>
Flexibilité	Limitée	<b>Élevée</b>

## Compromis

Gain substantiel en précision contre augmentation du temps de calcul



# Avantages de l'Architecture Hybride

## Avantages techniques :

- Spécialisation des modules
- Optimisation indépendante
- Gestion améliorée des variations (police de caractères, couleur des caractères, etc...)

## Avantages opérationnels :

- Réduction de 25% du temps d'annotation, donc plus rapide
- Infrastructure évolutive
- Maintenance facilitée

## Bilan

L'approche hybride offre un meilleur équilibre performance/coût avec une architecture adaptable.

## Cibles Quantifiées

$$\text{F1-score}_{\text{cible}} = 99\%$$

$$\mathcal{L}_{\text{CrossEntropy}} = 1 \times 10^{-3}$$

### Stratégies données :

- Collecte massive d'échantillons
- Data augmentation avancée
- Focus sur classes faibles

### Stratégies modèles :

- Fine-tuning architecture
- Apprentissage par transfert
- Optimisation du temps de calcul

## ① Court terme (1-3 mois)

- Augmentation du dataset
- Amélioration des classes faibles (O, J, P, D)

## ② Moyen terme (3-6 mois)

- Optimisation architecturale
- Réduction temps de calcul (objectif : 50 FPS)

## ③ Long terme (6-12 mois)

- Atteinte F1-score = 99%
- Déploiement industriel

## Précision

$$\text{Précision} = \frac{\text{Vrais Positifs}}{\text{Vrais Positifs} + \text{Faux Positifs}}$$

Parmi les prédictions positives, quelle proportion est correcte ?

## Rappel

$$\text{Rappel} = \frac{\text{Vrais Positifs}}{\text{Vrais Positifs} + \text{Faux Négatifs}}$$

Parmi les vrais positifs, quelle proportion est correctement prédicte ?

# Score F1 et Cross-Entropy

## Score F1

Moyenne harmonique entre précision et rappel :

$$F1 = 2 \times \frac{\text{Précision} \times \text{Rappel}}{\text{Précision} + \text{Rappel}}$$

**Exemple :** Précision = 90%, Rappel = 95%  $\rightarrow$  F1 = 92.4%

## Cross-Entropy Loss

Mesure l'erreur entre distributions prédites et réelles :

$$\mathcal{L}_{\text{CE}} = - \sum_{i=1}^N y_i \log(\hat{y}_i)$$

Plus cette valeur est faible, meilleure est la confiance du modèle.

# Conclusions et Perspectives

## Résultats Obtenus

- Architecture hybride **supérieure** à l'approche monolithique
- F1-score de **97.06%** (+3.48%)
- Réduction de **25%** du temps d'annotation
- Infrastructure évolutive et maintenable

## Vision Future

Objectif F1 = 99% positionne cette solution comme **compétitive pour des applications industrielles exigeantes.**

## Prochaines Étapes

Focus sur l'optimisation des classes faibles et la réduction du temps de calcul.

**Merci pour votre attention !**

# Questions ?

Commentaires et discussions

*info@uatm-gasa.com*